Mini-projeto: Árvores de Decisão

Prática / Experimentos

scikit learn

ANACONDA®

jupyter

CO

Prática / Experimentos

sklearn.tree.DecisionTreeClassifier

class sklearn.tree. **DecisionTreeClassifier** (*criterion='gini', splitter='best', max_depth=None, min_samples_split=2, min_samples_leaf=1, min_weight_fraction_leaf=0.0, max_features=None, random_state=None, max_leaf_nodes=None, min_impurity_decrease=0.0, min_impurity_split=None, class_weight=None, presort=False*)

[source]

Documentação do Scikit Learn

Prática / Experimentos

Conjunto de Dados Titanic

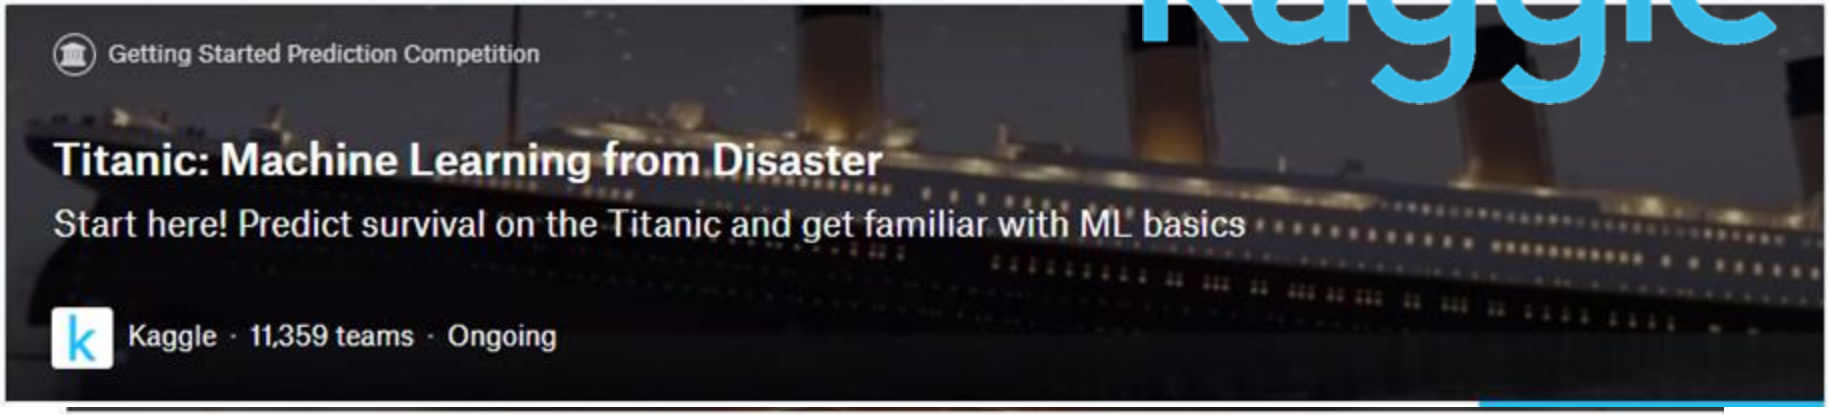

891 Observações, 12 Atributos (11 Descritores, 1 Atributo de Classe Binária)
Objetivo: Identificar se a pessoa sobreviveria ou não ao desastre do Titanic
Link: https://www.kaggle.com/c/titanic/data
Competição no Kaggle (Existe conjunto de Teste para submissão das predições)

Prática / Experimentos

Hiperparâmetros

- max_profundidade – profundidade máxima da árvore de decisão
- min_samples_split – Número mínimo de amostras que um nó deve possuir antes da divisão.
- min_samples_leaf – Número mínimo de amostras que um nó folha deve possuir.
- max_leaf_nodes – Número máximo de nós folha que uma árvore de decisão pode ter.
- max_features – Número máximo de variáveis que são levados em conta para dividir cada nó
- min_impurity_decrease – Impureza mínima alcançada quando um nó é dividido
- Pré-pruning ou Pós-pruning

Entrega

- Relatório – pode ser no próprio Jupyter notebook, comentado
- Apresentação do relatório: grupos sorteados no início da aula na data marcada
- ~15 páginas (pode ser mais, mas NÃO precisa ser extenso)
- Relatar os experimentos e resultados a medida que forem evoluindo
- Comentar sobre as mudanças de parâmetros buscando melhorar os resultados
- Analisar os dados traz insights interessantes para refinamentos (visualizar os valores das variáveis, distribuição, box plots, etc)
- Data: indicada no Classroom