Mini-projeto K-Means + K-Prototypes + DBSCAN

Prática / Experimentos

scikit learn

ANACONDA®

jupyter

CO

Prática / Experimentos

sklearn.cluster.KMeans

class `sklearn.cluster.` **`KMeans`** (*n_clusters=8, init='k-means++', n_init=10, max_iter=300, tol=0.0001, precompute_distances='auto', verbose=0, random_state=None, copy_x=True, n_jobs=None, algorithm='auto'*) [source]

Documentação do Scikit Learn

Prática / Experimentos

sklearn.cluster.DBSCAN

class `sklearn.cluster.`**DBSCAN**(*eps=0.5, *, min_samples=5, metric='euclidean', metric_params=None, algorithm='auto', leaf_size=30, p=None, n_jobs=None*) [source]

Perform DBSCAN clustering from vector array or distance matrix.

DBSCAN - Density-Based Spatial Clustering of Applications with Noise. Finds core samples of high density and expands clusters from them. Good for data which contains clusters of similar density.

The worst case memory complexity of DBSCAN is $O(n^2)$, which can occur when the `eps` param is large and `min_samples` is low.

Read more in the User Guide.

Parameters:

eps : *float, default=0.5*

The maximum distance between two samples for one to be considered as in the neighborhood of the other. This is not a maximum bound on the distances of points within a cluster. This is the most important DBSCAN parameter to choose appropriately for your data set and distance function.

Documentação do Scikit Learn

Prática / Experimentos

Medium Search Write

A Python implementation of K-Prototypes is available in the `kmodes` library. You can use the `KPrototypes` class to create a K-Prototypes model and fit it to your data. Here's how you can use it:

```
from kmodes.kprototypes import KPrototypes
from sklearn.metrics import silhouette_score
import numpy as np

# Define the range of potential clusters and gamma values
clusters_range = range(2, 10)
```

Prática / Experimentos

Conjunto de Dados Titanic

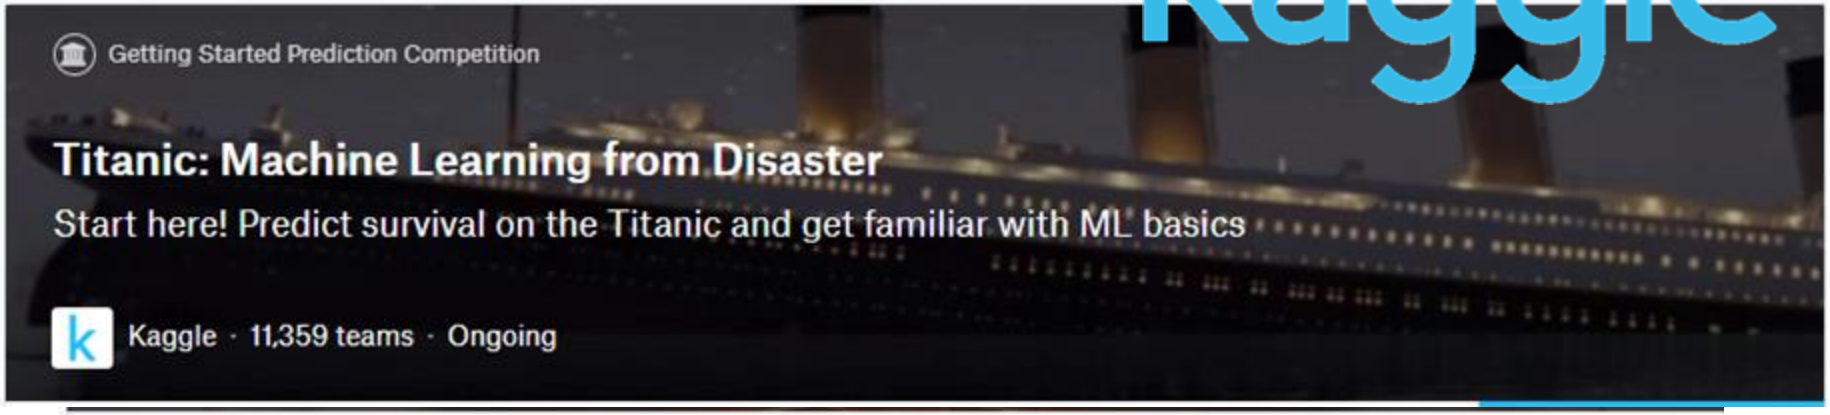

891 Observações, 12 Atributos (11 Descritores, 1 Atributo de Classe Binária)
Objetivo: Identificar se a pessoa sobreviveria ou não ao desastre do Titanic

ATENÇÃO!!! Para este problema, utilizar a base enviada via Classroom. Retiramos o alvo para vocês tratarem essa análise como um problema não supervisionado.

Diretrizes

- Compare os algoritmos K-Means, K-Prototypes e DBSCAN na criação de clusters;
- Uma solução não-supervisionada permite identificar padrões nos dados, ou seja, regularidades; E extrair conhecimento e características sobre os grupos;
- **ATENÇÃO:** O problema deve ser tratado de forma **não-supervisionada: remova o rótulo que indica se sobreviveu ou não;**
- **AVISO: Se o projeto for resolvido de maneira supervisionada será desconsiderado e receberá nota zero;**
- As métricas Elbow, Calinski-Harabasz, Davies-Bouldin, Silhouette e BIC devem ser usadas para indicar o melhor valor de k. O valor de k indicado pela maioria pode ser um critério de escolha; Disponíveis em (Github). (Are You Still Using the Elbow Method?);
- Quando os clusters tiverem definidos, calcular as distâncias Intra-clusters e Inter-clusters pode dar uma ideia de boa formação dos clusters;
- Em problema não supervisionado não há uma métrica conclusiva como há em problema supervisionado
- Quando tiver os clusters definidos, pode fazer “perguntas” em cada cluster. Por exemplo, como se distribuem os valores para a variável X em cada cluster? Qual o valor médio da variável Z em cada cluster? Quais as características principais em cada cluster?

Diretrizes

- Lembre-se, para algoritmos baseados em distância, a normalização dos dados é ponto chave;

- Após os grupos criados (digamos que o número de clusters sigerido foi k=3, pela maioria das métricas), você pode rotular os grupos como classes, como “grupo 1”, “grupo 2”, “grupo 3”, e usar uma árvore de decisão como algoritmo de classificação dos grupos;

- Após treinada, você pode usar uma função do python para extrair regras da árvore criada;

- Extract Decision Rules from Scikit-Learn Decision Tree | by Doug Creates | Medium https://medium.com/@Doug-Creates/extract-decision-rules-from-scikit-learn-decision-tree-5c242cde9a6d

```
DecisionTreeClassifier(random_state=0)
clf.fit(X, y)
```

20:04 ✓

```
|--- petal length (cm) <= 2.45
|   |--- class: 0
|--- petal length (cm) > 2.45
|   |--- petal width (cm) <= 1.75
|   |   |--- petal length (cm) <= 4.95
|   |   |   |--- class: 1
|   |   |--- petal length (cm) > 4.95
|   |   |   |--- class: 2
|   |--- petal width (cm) > 1.75
|   |   |--- petal length (cm) <= 4.85
|   |   |   |--- class: 2
|   |   |--- petal length (cm) > 4.85
|   |   |   |--- class: 2
```

20:05 ✓

Prática / Experimentos

K-means Clustering: Algorithm, Applications, Evaluation Methods, and Drawbacks | Towards Data Science

Entendendo DBSCAN (Em português)

Referências no Kaggle

k-Means
K-Prototypes
DBSCAN

kaggle Sign In Register

K-Means vs K-Prototype

Copy & Edit 106 11

Notebook Input Output Logs Comme >

Runtime

25s

Version 3 of 3

View Metadata

Introduction

Clustering is an unsupervised learning problem , its aim is to identify or discover interesting patterns from the data.

This aim of this tutorial is to apply K-means algorithm on numerical data , K-prototype algorithm on mixed data (numerical + categorical data) and analyze the properties of resulting clusters to gain insights

- **Part 1** : K-means clustering for numerical data.
- **Part 2** : K-prototype clustering on mixed data.

kaggle Sign In Register

Unsupervised Learning using K-pro

Notebook Input Output Logs Comme >

variables and Similarities for categorical variables and uses an assumed gamma as weightage (which decides the preference towards categorical or numerical variables), to assign points to a cluster. This is iteratively done by re-assigning points to the right clusters each time and stops when the desired number of moves or iterations has been achieved (Huang, 1997).

Gamma is guided by the average standard deviation of the numeric attributes. In cases where gamma is not specified (from domain knowledge), it is automatically calculated from the data. In our model, the parameter value of gamma was found to be 0.15 (which gave somewhat distinct clusters) after iteration using fractions of sigma, which is the standard deviation of the chosen numerical variables. Smaller values (closer to 0) of gamma favour the numerical variables while those larger favour (away from 0) the categorical variables (Huang, 1997).

In [40]:

```
#Getting the list of Numerical and Categorica
l Variables
num_cols = Data._get_numeric_data().columns
print (num_cols)
cols = Data.columns
```

https://www.kaggle.com/code/rishwinger/k-means-vs-k-prototype

https://www.kaggle.com/code/rohanadagouda/unsupervised-learning-using-k-prototype-and-dbscan

Entrega

- Relatório – pode ser no próprio Jupyter notebook, comentado
- Apresentação do relatório: grupos sorteados no início da aula na data marcada
- ~15 páginas (pode ser mais, NÃO precisa ser extenso)
- Relatar os experimentos e resultados a medida que forem evoluindo
- Comentar sobre as mudanças de parâmetros buscando melhorar os resultados
- Analisar os dados traz insights interessantes para refinamentos (visualizar os valores das variáveis, distribuição, box plots, violin plots, etc)
- Em aprendizagem não-supervisionada você busca extrair as características dos clusters
- Data: indicada no Classroom