Mini-projeto MLP

Prática / Experimentos

scikit learn

ANACONDA®

Prática / Experimentos

Leia sobre cada etapa detalhadamente: Microsoft

Prática / Experimentos

sklearn.neural_network.MLPClassifier

class sklearn.neural_network. **MLPClassifier** (*hidden_layer_sizes=(100,), activation='relu', solver='adam', alpha=0.0001, batch_size='auto', learning_rate='constant', learning_rate_init=0.001, power_t=0.5, max_iter=200, shuffle=True, random_state=None, tol=0.0001, verbose=False, warm_start=False, momentum=0.9, nesterovs_momentum=True, early_stopping=False, validation_fraction=0.1, beta_1=0.9, beta_2=0.999, epsilon=1e-08, n_iter_no_change=10*) [source]

Documentação do Scikit Learn

Prática / Experimentos

Conjunto de Dados Titanic

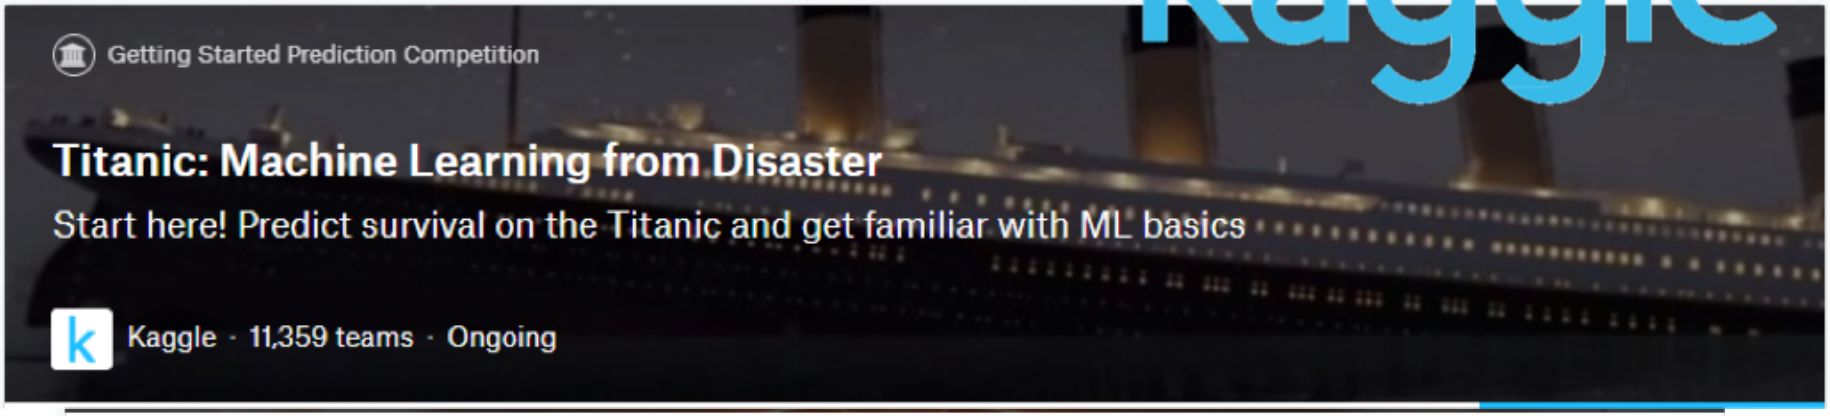

891 Observações, 12 Atributos (11 Descritores, 1 Atributo de Classe Binária)
Objetivo: Identificar se a pessoa sobreviveria ou não ao desastre do Titanic
Link: https://www.kaggle.com/c/titanic/data
Competição no Kaggle (Existe conjunto de Teste para submissão das predições)

Prática / Experimentos

Codificação de Atributos

- RN só aceitam como entrada e saída dados numéricos
  - Inteiros
  - Reais
  - Binários

- Simbólicos precisam ser codificados

©Germano Vasconcelos

Multilayer Perceptron (MLP) e Backpropagation

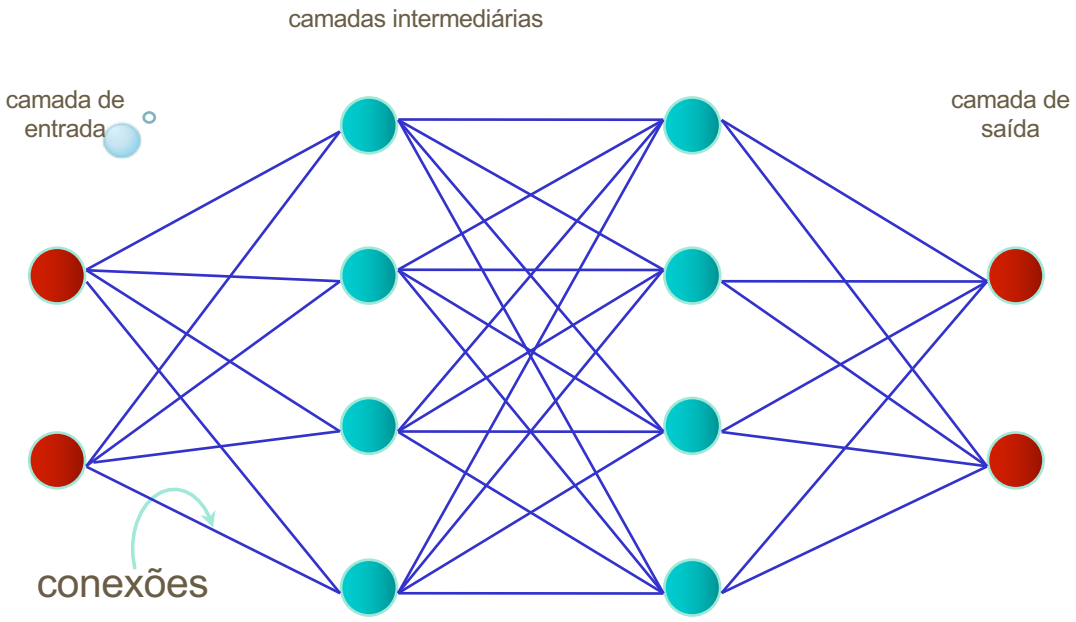

Como Codificar?

- Contínuos
  - Já estão adequadamente codificados
  - Devem ser normalizados
- Discretos numéricos
  - binários
    - Já estão adequadamente codificados
    - A não ser que uma transformação melhore a qualidade da representação (ex: transformar uma variável representada por vários bits em uma variável dummy (0 ou 1))
  - inteiros
    - Já estão adequadamente codificados
    - A não ser que uma transformação melhore a qualidade da representação (ex: transformar uma variável em uma variável dummy (0 ou 1)), transformar idade em faixas etárias
    - Devem ser normalizados
  - reais
    - Já estão adequadamente codificados
    - A não ser que uma transformação melhore a qualidade da representação (ex: transformar uma variável temperatura em faixasde temperatura
    - Devem ser normalizados

©Germano Vasconcelos

Como Codificar?

- Simbólicos
  - necessitam transformação
  - codificação binária
    - Densa (binary encoding). Escolhida se a variável simbólica tiver muitos valores possíveis (maior que 20, por exemplo);
    - esparsa (1 de N) (one hot encoding). Principal escolha para representação em código binário, prinipalmente quando a variável simbólica tiver menos valores (menor que 10, por exemplo);
    - intermediária (M de N). M de N bits são setados com 1, o resto com 0. Ex: 3 de 6 (100110). Uma opção ao one hot encoding para avaliar experimentalmente.

©Germano Vasconcelos

Normalização dos Dados

- **Normalização min-max (mais comum)**
  - Dados escalados dentro de um intervalo [-1.0 – 1.0, ou 0.0 – 1.0]

$$v' = \frac{v - \min_A}{\max_A - \min_A}(new_\max - new_\min) + new_\min_A$$

$$v' = \frac{73{,}600 - 12{,}000}{98{,}000 - 12{,}000}(1.0 - 0.0) + 0.0 = 0.716$$

  - Exemplo: Salário mínimo $12,000 e máximo $98,000, range [0.0, 1.0]. Normalizar um salário de $73,600.

Balanciamento de Classes

- Usar repetição dos dados da classe minoritária até ficar do mesmo tamanho da classe majoritária e depois embaralhar (repetitive oversampling)

- Ver a ordem explicada nos slides aseguir sobre Divisão dos Dados para não gerar contaminação nos dados

©Germano Vasconcelos

Divisão dos Dados

- Criação de conjuntos de dados independentes
  - Treinamento
  - Validação
  - Teste
- Estatisticamente representativos e independentes
  - Não pode haver sobreposição

©Germano Vasconcelos

Particionamento dos Dados – Primeira etapa
Estratégia 50% Treinamento, 25% Validação, 25% Teste

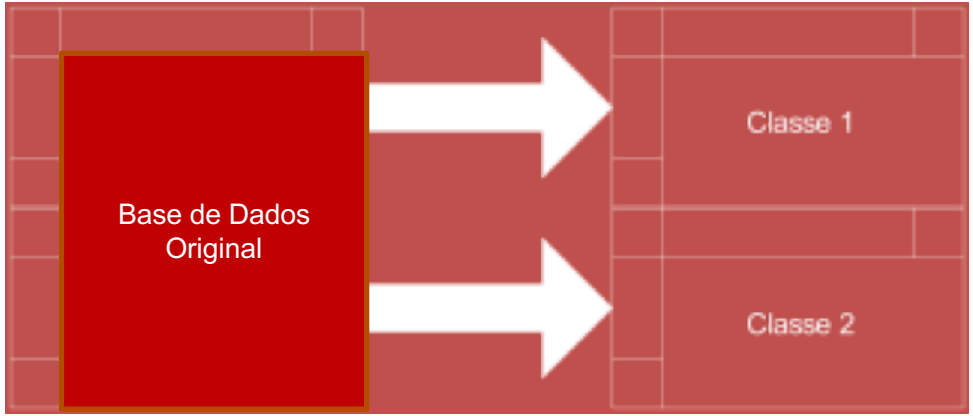

©Germano Vasconcelos

Particionamento dos Dados – Segunda etapa

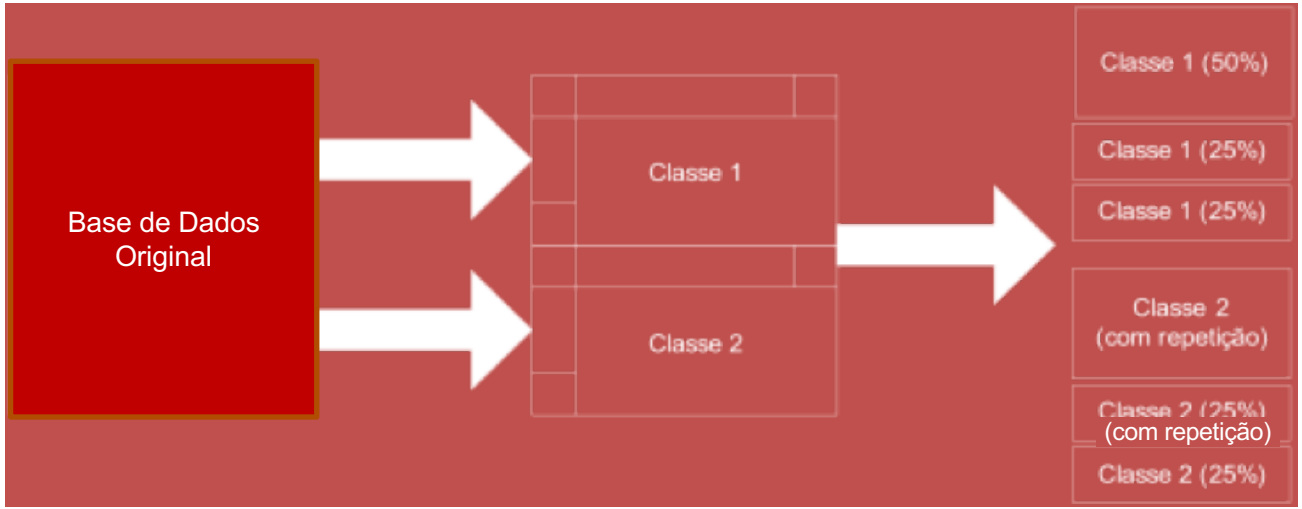

©Germano Vasconcelos

Particionamento dos Dados – Etapa Final

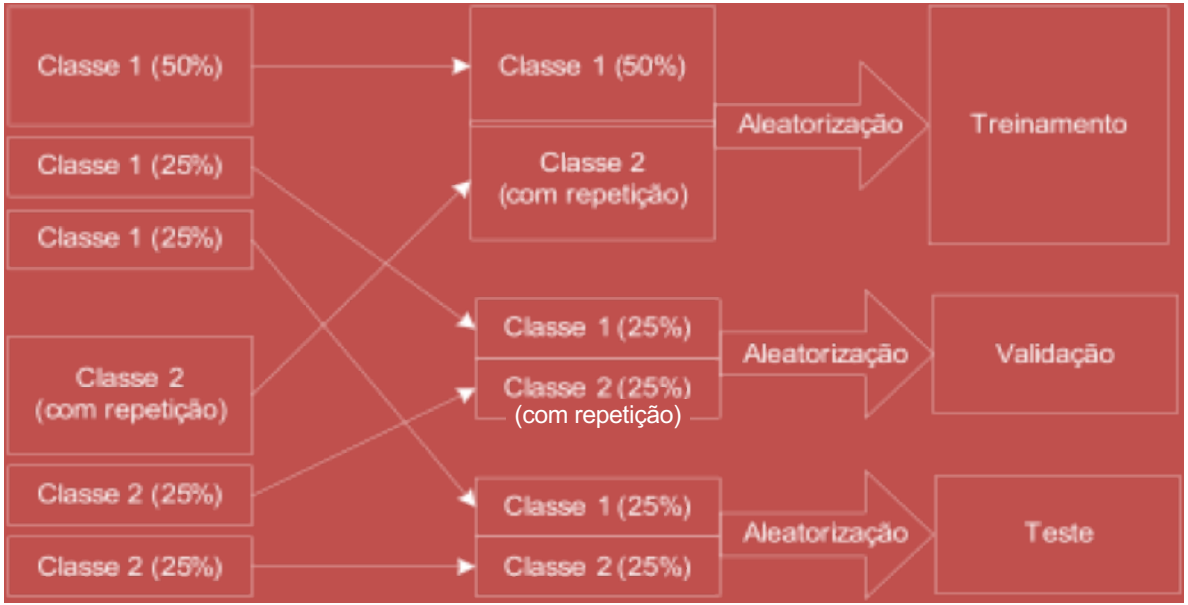

Particionamento dos Dados com K-folds – Estratégia Mais Robusta Para o Miniprojeto usar a mais simples 50%, 25%, 25%

K-fold Cross Validation

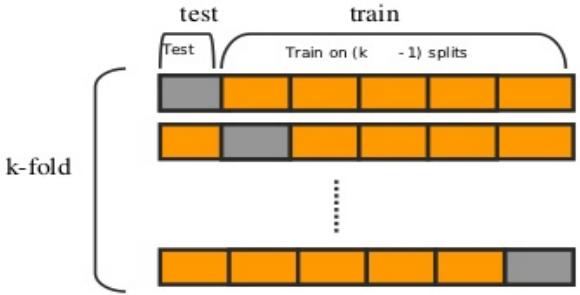

OBS: use 1 fold para validação também em cada rodada

- Randomly divide your data into K pieces/folds
- Treat 1st fold as the test dataset. Fit the model to the other folds (training data).
- Apply the model to the test data and repeat k times.
- Calculate statistics of model accuracy and fit from the test data only.

Hiperparâmetros

- Número de camadas
- Número de unidades escondidas
- Variação da taxa de aprendizagem
- Função de ativação (logistica, tangent hiperbolica, Relu)
- Otimização: Adam, Drop-out, Regularização

©Germano C.Vasconcelos

Entrega

- Relatório – pode ser no próprio Jupyter notebook, comentado
- Apresentação do relatório: grupos sorteados no início da aula na data marcada
- Entrega do relatório obrigatoriamente em PDF e o código do notebook
- +-15 páginas (pode ser mais, mas NÃO precisa ser extenso)
- Relatar os experimentos e resultados a medida que forem evoluindo
- Comentar sobre as mudanças de parâmetros buscando melhorar os resultados
- Analisar os dados traz insights interessantes para refinamentos (visualizar os valores das variáveis, distribuição, box plots, etc)
- Data: indicada no Classroom